

SAP-Assignment 2

Shipping on the Air

Marco Morelli

1. QUALITY ATTRIBUTES

Il sistema descritto in questa relazione è un prototipo di consegna pacchi tramite droni, evoluzione dell' Assignment 01, in cui il design, l'implementazione e il deployment vengono raffinati applicando un sottoinsieme di microservices pattern. Prima di descrivere i pattern vengono individuati due **Quality Attribute (QA)** rappresentativi, di cui si specifica lo scenario: essi costituiscono le due proprietà che i pattern di observability rendono osservabili e verificabili, e sono verificati **end-to-end** secondo quanto descritto nella Sezione 4.

Il primo QA riguarda la **responsiveness** e ne fissa il requisito minimo in condizioni di overload.

QA Scenario: Responsiveness

Quality attribute scenario : Responsiveness

Feature : Small average response time in case of overload
when initiate 1000 concurrent requests
caused by 1000 users
occur in the system
operating in normal operation
then the system processes all requests
so that the average response time is < 100 milliseconds

Il secondo QA riguarda la **gestione dei partial failure**: quando l'account service diventa irraggiungibile, il sistema deve evitare di propagare richieste destinate a fallire.

QA Scenario: Handling partial failures

Quality attribute scenario : Handling partial failures

Feature : Avoid pointless requests in case of unavailability of the account service
when more than 50% of total requests fail
caused by unavailability of the account service
occur in the system
operating in normal operation
then the system makes the requests fail immediately
without propagating to the account service
so that it lightens the workload avoiding pointless requests

I due scenari orientano le scelte architetturelle: la responsiveness motiva l'adozione di un modello di I/O non bloccante del gateway e la misura del tempo di risposta a livello di edge; la gestione dei partial failure motiva il **Circuit Breaker** sui proxy del gateway. In entrambi i casi un pattern realizza la proprietà e una metrica **Prometheus** la rende verificabile.

2 DEPLOYMENT

Ogni microservizio è deployato in un singolo container Docker. L'intero sistema è orchestrato con **Docker Compose**, che consente di avviarlo con un solo comando (*docker compose up --build*) a partire dalle immagini buildate direttamente dai rispettivi Dockerfile. Tutti i servizi condividono un'unica rete (*shipping_network*): questa rete condivisa permette di abilitare il **Service Discovery via DNS** e lo scrape di **Prometheus**.

I **container** usano base image *eclipse-temurin-25* e vengono avviati come *fat-jar*. Tale scelta è preferibile all'avvio tramite *mvn exec:java* perché quest'ultimo comporta l'esecuzione di **Maven** a runtime e rende l'avvio del servizio più lento e meno prevedibile. Poiché il container è sottoposto a un *healthcheck* e alla supervisione dell'*autoheal*, un avvio lento può innescare un loop di restart: se l'*healthcheck* inizia a sondare il servizio prima che questo sia pronto a rispondere, il container viene marcato *unhealthy* e riavviato, dando origine a un ciclo in cui il servizio non riesce mai a stabilizzarsi.


La **persistenza** è volontariamente effimera: non viene montato alcun volume, cosicché lo stato scritto a runtime non sopravvive alla ricreazione del container. L'event store del delivery viene inoltre azzerato attivamente a ogni avvio, mentre il repository degli account si limita a ricaricare il proprio file, che in assenza di volume risulta comunque vuoto a ogni boot pulito. *AdminSeeder* e *FleetSeeder* riseminano l'account amministratore e i droni, garantendo uno stato deterministico a ogni *docker compose up*. Si tratta di una scelta consapevole, coerente con la natura di prototipo del sistema: si rinuncia deliberatamente alla durabilità della storia, uno dei benefici dell'Event Sourcing, in favore di uno stato iniziale coerente e riproducibile, evitando al contempo che una storia sopravvissuta si disallinei dalla flotta riseminata da zero. Il caricamento da store persistente è comunque implementato e verificato dai test di replay.

Relativamente alle **restart policy**, è stata adottata una configurazione non uniforme e motivata. I servizi *account-service*, *api-gateway* e *prometheus* adottano *restart: always*, mentre il *delivery-service* non prevede riavvio automatico. La differenza risiede nella natura dello stato dei due servizi

applicativi. Lo stato dell'*account-service* è disaccoppiato: un suo riavvio lo riporta a uno stato valido (con l'amministratore riseminato), eventualmente più povero dei sender registrati a runtime, ma senza introdurre incoerenze verso gli altri servizi, di cui resta proprietario delle identità. Lo stato del *delivery-service* è invece accoppiato a runtime: la flotta è condivisa logicamente con il gateway, che sta facendo relay sulle WebSocket di tracking, e con i client che stanno tracciando le consegne attive. Se il *delivery-service* risorgesse da solo dopo un crash, azzerando il proprio event store mentre il gateway e gli altri servizi restano attivi, si reintrodurrebbe silenziosamente uno stato di flotta disallineato. Rinunciando al riavvio automatico, un eventuale crash resta visibile anziché essere mascherato.

3 PATTERNS

Rispetto all' Assignment 01 sono stati applicati i seguenti pattern: **API Gateway, Health Check API, Application Metrics, Event Sourcing, Service Discovery e Circuit Breaker**. L' architettura rimane esagonale con *DDD*: ogni servizio è un progetto Maven autonomo e self-contained. Il sistema finale è composto da tre microservizi deployabili: *account-service*, *delivery-service* e *api-gateway*.



Vista C&C di sistema


3.1 API Gateway

È stato introdotto un microservizio **api-gateway** come unico endpoint del sistema, con il compito di nascondere la composizione interna dei servizi. Esso espone la **REST API** lato client e, tramite l'*APIGatewayController*, instrada ogni richiesta al servizio a valle sfruttando una routing map e i relativi proxy (*AccountServiceProxy*, *DeliveryServiceProxy*), ereditati e adattati dai proxy del *session-service* dell' Assignment 1.

La scelta architetturale più significativa è che il **gateway assorbe la facciata del session-service**. Nell' Assignment 1 esisteva un orchestratore sottile che aveva un ruolo coincidente con quello che il pattern **API Gateway** assegna al gateway (request routing ed edge function di autenticazione). Mantenere un servizio separato dedicato al solo routing e alla sessione davanti a un gateway che già instrada avrebbe comportato una duplicazione di responsabilità e un ulteriore hop di rete privo di beneficio. Con la fusione si ottiene un unico endpoint coerente con il pattern e una minore superficie di rete.

Poiché il pattern impone che ogni richiesta del client transiti dal **gateway**, anche la registrazione, precedentemente diretta all'*account-service*, è instradata dal gateway; essa resta tuttavia routing puro, mentre l' operazione di dominio e la relativa invariante resta nell'*account-service*.

Il tracking real-time, realizzato precedentemente con una WebSocket diretta *client-delivery*, ora diventa un **relay in due tratte**: il gateway accetta la WebSocket dal client e apre una WebSocket interna verso il delivery, facendo da relay dei messaggi di posizione ed ETR. Il trade-off, che si documenta, è che il gateway mantiene una connessione aperta per ciascun utente che effettua il tracking.



C&C dell'api-gateway

3.2 Observability Patterns

3.2.1 Health Check API

Ogni servizio espone un endpoint di health check. Sul gateway si sono distinti **liveness** e **readiness**:

- *GET /api/v1/health/live (liveness)*: risponde sempre 200/UP senza interrogare i downstream, a indicare che il processo del gateway è attivo.
- *GET /api/v1/health (readiness aggregato)*: sonda account e delivery e risponde 200/UP se entrambi sono disponibili, 503/DOWN altrimenti.

Questa distinzione ha una conseguenza operativa precisa: l' *healthcheck* di **Docker Compose** è configurato sulla *liveness*, cosicché l' *autoheal* riavvia il gateway solo se il processo è effettivamente terminato. Con un unico health aggregato, l'indisponibilità di un downstream avrebbe reso il gateway *unhealthy*, inducendo l'autoheal a riavviarlo inutilmente e mascherando così il vero guasto. Il readiness resta invece utile per la diagnosi e per la chiusura del Circuit Breaker.

3.2.2 Application Metrics

Si utilizza **Prometheus**, aggiunto al **Compose** e configurato tramite *prometheus.yml*. Due servizi espongono metriche, ciascuno su una porta dedicata indicata per **DNS name**.

Il Service Discovery abilita lo scrape:

delivery-service

metriche di livello applicativo (porta 9400):

- `created_deliveries`: numero totale di consegne create.
- `deliveries_in_progress`: consegne attualmente in corso.
- `deliveries_delivered`: numero totale di consegne completate.

api-gateway

metriche di livello infrastrutturale (porta 9401):


- `rest_requests`: numero totale di richieste REST.
- `request_response_time_seconds`: tempo di risposta cumulativo in secondi (QA responsiveness).
- `account_circuit_open`: stato del Circuit Breaker dell'account (QA partial failures).

Coerentemente con l'architettura esagonale, la metrica risiede **al di fuori della business logic**: il *delivery-service* impiega l'adapter *PrometheusDeliveryServiceObserver* per esporre le metriche implementando l'interfaccia *DeliveryServiceEventObserver*, mentre il gateway impiega *PrometheusControllerObserver* per le metriche implementando *ControllerObserver*, osservato dall'*APIGatewayController*.

3.3 Event Sourcing

L'Event Sourcing è applicato al **delivery-service**: è il servizio che meglio si presta a essere strutturato a eventi, poiché il ciclo di vita di una consegna è già una sequenza di transizioni di stato per le quali erano stati definiti domain event. L'aggregate *Delivery* è persistito come **sequenza di eventi**, e non come stato: una porta applicativa *EventStore* con adapter *FileBasedEventStore*, e un *EventSourcedDeliveryRepository* che effettua l'append degli eventi e ricostruisce l'aggregate tramite replay.

Ogni transizione di stato emette un evento e ogni tipo di evento dispone del proprio ramo in *apply()*, cosicché il replay non può mai fallire. Un solo evento, *EstimatedTimeUpdated*, è escluso dalla persistenza: esso rappresenta il tempo stimato residuo, che varia a ogni tick del volo e costituisce un dato di **read-model volatile**; persisterlo gonfierebbe lo store senza apportare valore storico. Si mantengono così distinti due piani: la **persistenza a eventi** (event store, lato write) e la **notifica a eventi** (Observer in-process per tracking e metriche).



C&C del delivery-service

3.4 Service Discovery

Il Service Discovery è realizzato a **livello di deployment tramite Docker**: la piattaforma dispone di un service registry integrato e di un *DNS resolver* interno, e assegna a ogni servizio un DNS name. I proxy del gateway puntano ai nomi logici (*account-service*, *delivery-service*), letti da variabili d'ambiente (*ACCOUNT_HOST/DELIVERY_HOST*) con default localhost, e non a indirizzi IP.


3.5 Circuit Breaker

Il **Circuit Breaker** è applicato nei proxy del gateway in modo da risolvere parzialmente il problema legato alla possibilità di **partial failure** durante la comunicazione sincrona con altri servizi.

Il **CircuitBreaker** modella tre stati *CLOSED / OPEN / HALF_OPEN*. Esso traccia i successi e i fallimenti su una finestra con volume minimo: superata la soglia del **50%** di fallimenti, il circuito si apre e il gateway risponde immediatamente con errore senza inoltrare la richiesta. Trascorso un **timeout di 10 secondi**, il breaker passa in *HALF_OPEN* e sonda l'*health* del servizio: se questo è tornato disponibile, il circuito si richiude.

L'aspetto architeturalmente più delicato è **che cosa costituisce un fallimento**. Il breaker conta esclusivamente i guasti del downstream: errori di trasporto o timeout del WebClient e risposte 5xx. Non concorrono invece le risposte applicative 4xx, che indicano che il servizio ha risposto correttamente rifiutando l'input.

Il breaker alimenta la metrica *account_circuit_open* (tramite callback di cambio stato), rendendo osservabile il QA sui partial failure. Il relay WebSocket non attraversa il breaker, trattandosi di uno stream e non di un'interazione request/response sincrona.



C&C dell'account-service

4 TESTING

La strategia di test copre l'intera **test pyramid**. Unit, integration e component test risiedono nel *src/test* di ciascun servizio. Gli end-to-end test risiedono in un modulo separato di soli test (*system-end-to-end*). In ogni servizio sono inoltre presenti test architeturali ArchUnit, che verificano il rispetto dell'architettura esagonale.

4.1 Unit testing

Gli **unit test** seguono la distinzione *solitary/sociable* in base al ruolo della classe. Nel *delivery-service*, ad esempio, il dominio è testato in modalità **sociable** (aggregate Delivery, value object quali peso, coordinate, deadline ed ETR, aggregate Drone), poiché la logica è distribuita tra più oggetti mentre l'application (*DeliveryServiceImpl*) è testata in modalità **solitary**, con le porte mockate.

4.2 Integration testing

Gli **integration test** verificano l'interazione con i sistemi esterni senza avviare l'intera applicazione. Un esempio rappresentativo è il *DeliveryServiceProxy* del gateway verificato contro un delivery service simulato, che ne valida il contratto **REST** verso il servizio a valle. A questo livello si collocano anche i test dell'event store su file, dello scheduler a timer reale, del relay WebSocket, dell'health aggregato e dell'esposizione delle metriche **Prometheus**.

4.3 Component testing

I **component test** verificano un singolo servizio come *black box*, attraverso la sua API, mediante **Cucumber/Gherkin**:

- **account-service**: registrazione, login.
- **delivery-service**: creazione immediata e programmata, rifiuti di dominio, avvio del tracking e viste read-only dell'amministratore su flotta e scheduling.

4.4 End-to-end testing

Gli **end-to-end test** sono richieste esterne verso il sistema completo, effettuate dopo *docker compose up*, secondo l'approccio **user journey**. Sono definiti due journey:

- **Creazione delivery**: registrazione → login → creazione immediata → recupero del dettaglio. Esercita la catena gateway → account → delivery.
- **Tracciamento delivery**: (registrazione, login e creazione come precondizioni) → avvio del tracking via relay WebSocket (ricezione di frame reali) → lettura dello status → arresto. Verifica il relay client-gateway-delivery.

Nello stesso modulo risiedono i due test che verificano i **QA** scenario della Sezione 1, ed è in questo punto che observability e pattern si compongono in un'unica storia:

- **PerformanceTest (responsiveness)**: invia 1000 richieste concorrenti al gateway e calcola il tempo medio dal *delta* delle metriche, verificando che resti al di sotto di 100 ms. Il probe interroga la liveness, così da misurare la latenza del solo gateway senza falsi 503 sotto carico.
- **CircuitBreakerTest (partial failures)**: disconnette effettivamente l'account dalla rete Docker, osserva la gauge

account_circuit_open passare a 1, riconnette il servizio e verifica il ritorno a 0. Il gradino 0→1→0 costituisce la prova visiva del pattern.

5 CONCLUSIONI

L'adozione di Docker e Docker Compose ha reso il sistema portabile, riproducibile ed estendibile con un solo comando di avvio; il container per servizio garantisce isolamento e un minore accoppiamento a runtime.

L'applicazione dei pattern ha migliorato il sistema su assi distinti:

- L'API Gateway incapsula la struttura interna dietro un unico endpoint e assorbe la facciata del preesistente session-service.
- Gli observability pattern abilitano il monitoraggio, la diagnosi e l'alerting.
- L'Event Sourcing struttura la persistenza della consegna come storia di eventi.
- Service Discovery e Circuit Breaker accrescono la robustezza del sistema rispetto alla sua natura distribuita.

Il valore architetturale non risiede unicamente nell'aver introdotto i pattern, bensì nell'averli integrati in modo coerente: i due Quality Attribute sono realizzati da un pattern e resi verificabili da una metrica, e la copertura di test lungo l'intera pyramid, culminata negli user journey e nei due test di QA end-to-end, collega la correttezza delle singole funzionalità a quella delle comunicazioni tra i servizi e del sistema nel suo complesso.